# Trabajo práctico

# Laboratorio de Datos

**Integrantes:** Maite Alice, Abril Echarri y Facundo Miguel.

**LU:** 53/24, 64/24 y 702/24. (respectivamente)

**Mails**: maitealice2312@gmail.com, abril.echarri@gmail.com y facumiguel4025@gmail.com.

**Trabajo presentado el miércoles 21/5/2025**

# Resumen

El objetivo principal de este trabajo práctico de la materia “Laboratorio de Datos” es investigar si existe algún patrón o relación entre la cantidad de Establecimientos Educativos (EE) y la de Bibliotecas Populares (BP) en las diferentes provincias y departamentos de Argentina, usando datos oficiales del censo 2022. Para ello seguimos los siguientes pasos:

1. Revisión y limpieza de datos: examinamos la calidad de los datasets de EE y BP, aplicando el enfoque GQM (Goal–Question–Metric) para cuantificar problemas de completitud e inconsistencia.
2. Modelado: diseñamos un DER en 3FN y su correspondiente modelo relacional.
3. Preparación: Con Python, Pandas y SQL limpiamos y creamos las respectivas tablas guiándonos de nuestro modelo relacional.
4. Consultas y visualizaciones: Mediante SQL, Pandas y Matplotlib obtuvimos tablas que resumen cantidades de EE y BP por departamento, así como visualizaciones que muestran la distribución y una posible relación entre ambas variables.

# Introducción

En este trabajo vamos a analizar si existe una relación entre la cantidad de Establecimientos Educativos (EE) y Bibliotecas Populares (BP) en las distintas provincias y departamentos de Argentina. La idea es ver si hay algún tipo de patrón entre estos dos espacios.

Para eso, partimos de datos oficiales del año 2022 y empezamos revisando qué tan completa y confiable es la información. Después, armamos un Diagrama de Entidad-Relación (DER) en tercera forma normal y un modelo relacional, seleccionando sólo los datos que realmente necesitábamos para responder a nuestro objetivo. Además, revisamos la calidad de los datos aplicando la técnica GQM (Goal-Question-Metric), que nos permite elaborar métricas para cuantificar la gravedad de los problemas.

Luego, trabajamos en Python para limpiar y preparar los datasets. Una vez listos, hicimos consultas y visualizaciones usando herramientas como Pandas y Matplotlib. Todo esto nos ayudó a explorar las posibles relaciones entre EE y BP y ver cómo varían según la región.

# Procesamiento de Datos

### 1. Análisis de las formas normales

<u>Establecimientos Educativos (EE):</u>

La tabla original no cumple con la Primera Forma Normal (1FN), ya que contiene atributos no atómicos. Por ejemplo, en la columna de teléfono hay casos donde se listan dos números en una misma celda, lo mismo ocurre con el campo de mail. Esto viola el principio de atomicidad requerido por la 1FN.

Tampoco cumple con la Tercera Forma Normal (3FN), ya que se identificaron dependencias transitivas entre atributos que no forman parte de la clave primaria. Por ejemplo, el código de localidad depende de la localidad, y el código postal (CP) depende del domicilio.

Por lo tanto, como la tabla de EE no se encuentra en primera forma normal, tampoco se encuentra en segunda o tercera forma normal.

Bibliotecas Populares (BP):

La tabla de BP tampoco cumple con la Primera Forma Normal (1FN), principalmente porque contiene varios campos vacíos (como web, subcategorías, piso, observaciones e información adicional) y, en algunos casos, campos no atómicos. Un ejemplo de esto es una celda de mail que contiene dos direcciones de correo electrónico.

En cuanto a la Tercera Forma Normal (3FN), tampoco se cumple. Observamos muchas dependencias transitivas entre atributos no clave, como por ejemplo:

- El código de localidad depende de la localidad.
- El ID de provincia depende del nombre de la provincia.
- El ID de departamento depende de la provincia
- El código de teléfono depende del teléfono.
- El código postal (CP) depende del domicilio.

**2. Revisión de la calidad de datos de las fuentes y descripción de los problemas encontrados**

Bibliotecas Populares (BP)

1. Atributo de calidad afectado: Completitud
2. Tipo de problema: Instancia (valores faltantes en registros específicos).
3. Descripción del problema: Se observó que una proporción importante de registros no contiene ninguna dirección de correo electrónico, lo cual reduce la utilidad del campo y distorsiona cualquier análisis que se quiera hacer sobre él.
4. Aplicación de la técnica GQM:
    - **Goal (Objetivo)**: Asegurar la completitud de los datos en la columna Mail para garantizar un análisis representativo.
    - **Question (Pregunta)**: ¿Cuál es la proporción de registros con valor nulo en la columna Mail?
    - **Métrica** :"(Cantidad de valores nulos" / "Cantidad Total de valores)*100"
    - **Resultado**: `46.267087276550996 %`

5. **Diagnóstico y acción propuesta**: La gran cantidad de valores faltantes limita la posibilidad de sacar conclusiones. Como solución, se podría marcar los registros sin mail como "no disponible" para diferenciarlos de errores de carga, o intentar recuperar esa información a partir de otras fuentes oficiales si fuera posible.

Establecimientos Educativos (EE)

**Problema 1** : Completitud

1. Atributos de calidad afectados: Completitud y Interpretabilidad

2. Tipo de problema: Instancia, aunque también podría considerarse un problema de modelo si se concluye que el diseño actual favorece la ambigüedad.

3. Descripción del problema: Dentro del campo ‘Común’ (y sus subcolumnas: Jardín maternal, Jardín de infantes, Primario, Secundario, etc.) se detecta una gran cantidad de valores nulos. Esto genera dudas sobre si esos nulos significan “no aplica”, “no disponible” o “error de carga”.

4. Aplicación de la técnica GQM:
    - **Goal (Objetivo)**: Reducir la cantidad de valores nulos en la columna ‘Modalidad’ (subcampo clave de ‘Común’) para mejorar la calidad de la información.

    - **Question (Pregunta)**: ¿Cuál es el porcentaje de valores nulos en la columna ‘Modalidad’?

    - **Metric (Métrica)**: “Cantidad de valores nulos” / “Cantidad Total de valores”

    - **Resultado**: 21.03%.

5. **Diagnóstico y acción propuesta**: El porcentaje de nulos es muy elevado. Para resolverlo, se propone normalizar los datos: crear una tabla separada llamada Modalidades con las columnas ‘ID_EE’ y ‘Modalidad’, permitiendo múltiples modalidades por EE. Esta separación ayudaría a reducir los nulos, representar mejor los datos y hacer más flexible el análisis.

**Problema 2**: Inconsistencia.

1. Atributo de calidad afectado: consistencia.
2. Tipo de problema: Puede deberse tanto al modelo (si no hay restricciones de formato en el diseño de la base) como a instancias específicas (si el ingreso de datos fue manual o sin validaciones).
3. En la columna "Teléfono" de la tabla de establecimientos educativos se detectan varias inconsistencias en los datos. Algunos registros contienen caracteres no numéricos adicionales, como letras, por ejemplo: `4783-0889 INT119`, lo que indica posiblemente la inclusión de una extensión u otra información irrelevante en el mismo campo. Otros registros contienen múltiples números en una misma celda, separados por caracteres como , por ejemplo: `4578-3456/2345-7484` , lo que dificulta su validación y uso automatizado.
4. Aplicación de la técnica GQM:
    - **Goal (Objetivo)**: Asegurar la consistencia en los datos de la columna Teléfono.
    - **Question (Pregunta)**: ¿Cuál es la proporción de teléfonos inconsistentes en la columna teléfono?

- **Métrica**: (“Cantidad de teléfonos inconsistentes” / “Cantidad total de teléfonos”)*100
- **Resultado**: `85.64585%`

5. **Diagnóstico y acción propuesta:** Se detectaron numerosos valores no estandarizados en la columna de número de teléfono. Como primera medida de limpieza, se propone conservar únicamente uno de los números en los casos donde se presentan múltiples teléfonos en un mismo campo (por ejemplo, separados por una barra). En los registros que incluyen letras, como en el caso de “4783-0889 INT119”, se interpreta que el número principal es “4783-0889” y “119” corresponde a un interno (extensión), por lo tanto se conservará únicamente el número principal. Del mismo modo, en los casos en los que un número finaliza con una barra seguida de cuatro dígitos (ej. “4865-0878/0945”), se asume que esos cuatro dígitos representan un número interno, por lo que también se opta por conservar sólo el número principal.

**3. DER**

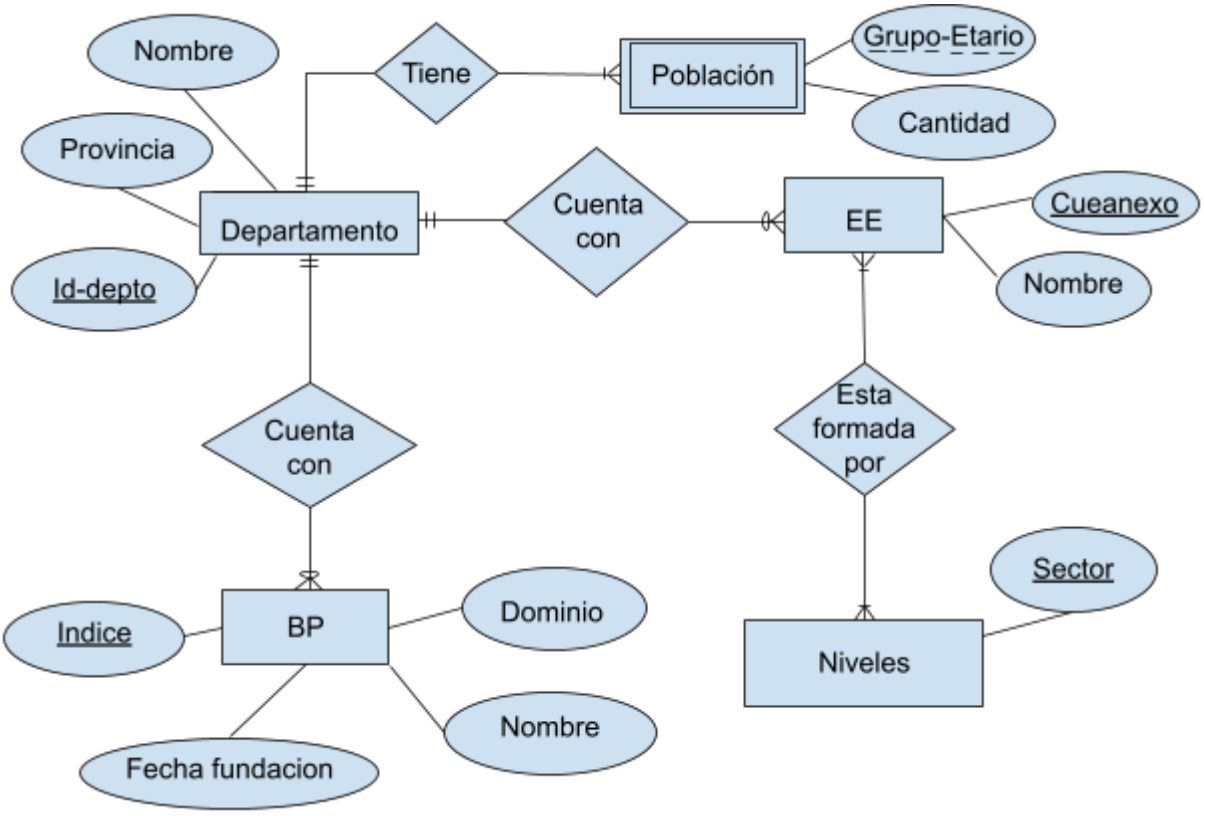


Aclaraciones del DER

**Departamento**
Es una entidad con los siguientes atributos: id_depto (clave primaria), Nombre y Provincia.
Se relaciona con:

- Población (entidad débil) mediante la relación *Tiene*.
- Establecimientos Educativos (EE) y Bibliotecas Populares (BP) mediante la relación *Cuenta con*.

**Población**
Entidad débil asociada a Departamento. Atributos: Grupo_Etario (clave parcial) y Cantidad. La super clave es {id_depto, Grupo_Etario}. Representa la cantidad de personas por grupo etario en cada departamento.

**EE (Establecimientos Educativos)**
Entidad con atributos: Cueanexo (clave primaria) y Nombre.
Se relaciona con:

- Departamento, mediante la relación *Cuenta con*.
- Niveles, mediante la relación *Está formada por*, que representa los niveles educativos que se dictan en cada EE.

**Niveles**
Entidad con atributos: Nombre y Sector (clave primaria).
Se relaciona con EE a través de la relación *Está formada por*.

**BP (Bibliotecas Populares)**
Entidad con atributos: Índice (clave primaria), Nombre, Fecha fundación y Dominio.
Se relaciona con Departamento a través de la relación *Cuenta con*.

- **Tipos de relaciones**

  <u>Departamento – Población</u>
  Relación uno a muchos: cada departamento puede registrar múltiples grupos de población, pero Población es una entidad débil, depende del id_depto, y cada grupo de población corresponde a un único departamento.

  <u>Departamento – EE</u>
  Relación uno a muchos: un EE pertenece a un único departamento, pero un departamento puede tener muchos EE.

  <u>EE – Niveles</u>
  Relación muchos a muchos: un EE puede estar formado por varios niveles, y niveles contiene a muchos EE.

  <u>Departamento – BP</u>
  Relación uno a muchos: una BP está en un único departamento, pero un departamento puede contar con muchas BP**.**

## 4. Modelo relacional

En el siguiente diagrama vemos las entidades y sus respectivos atributos. Las identificamos de la siguiente forma:

- Las **claves primarias** (PK) están subrayadas, en negrita y con una 🔑
- Las **foreign keys** (FK) están indicadas con una flecha gris.

- Las **dependencias funcionales** (DF) son las siguientes:
    - Población (id_depto, grupo_etario) → cantidad
    - Departamento (id_depto) → (nombre, provincia)
    - EE (cueanexo) → id_depto
    - BP (Índice) → (fecha_fundación, nombre, id_depto, dominio)

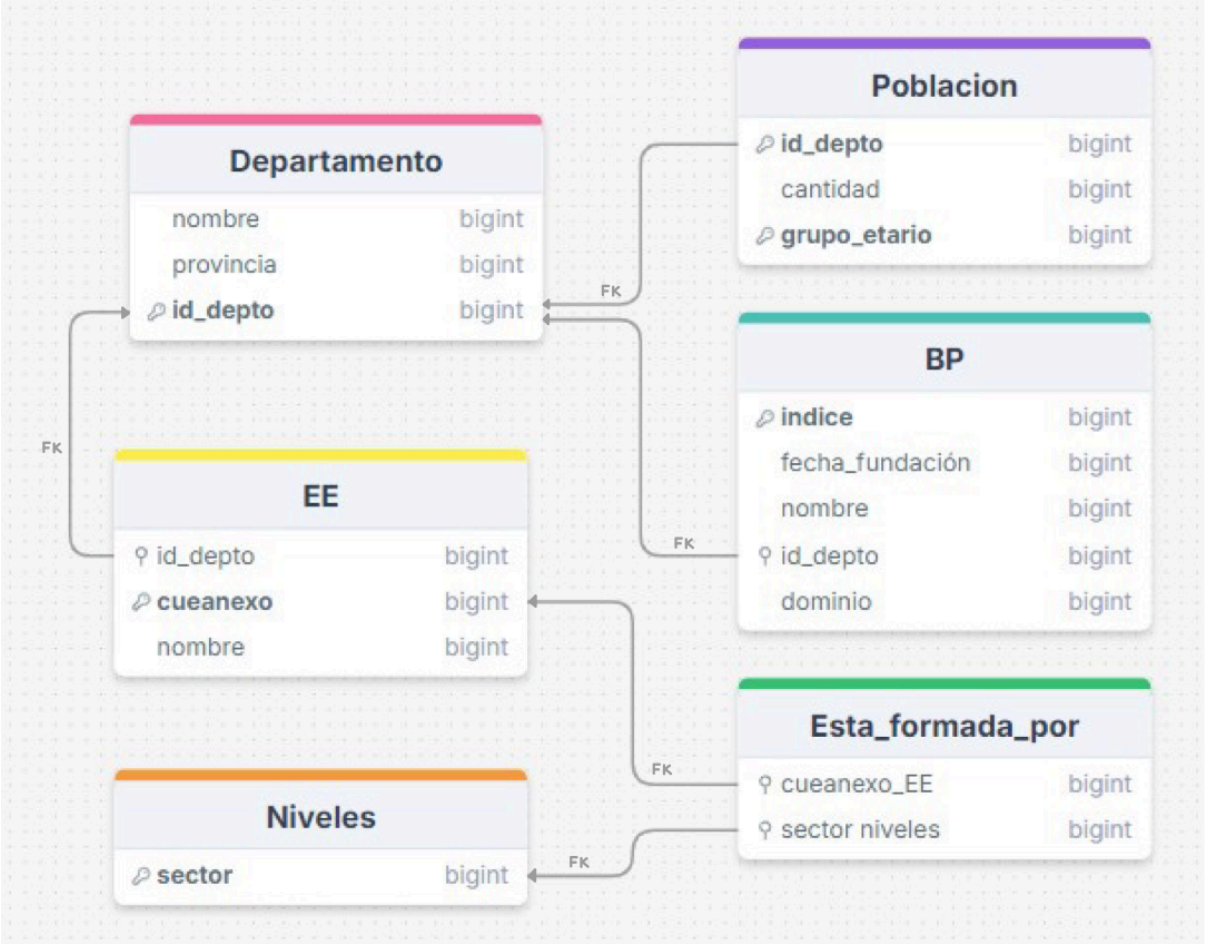


**5. Importación de datos**

Pasamos a la parte de importación de datos, donde empezamos a armar los DataFrames que vamos a usar según nuestro Modelo Relacional.

El primero que creamos es **Población**, con los campos: **Depto** (nombre del departamento), **Grupo_Etario** (dividimos las edades en 4 grupos: jardín, primario, secundario y todos) y la **Cantidad** de personas por grupo en cada departamento.

Después armamos el DataFrame **EE** (Establecimientos Educativos). Usamos los campos **cueanexo**, **nombre** y **jurisdicción**, a la que llamamos,por conveniencia, provincia. Esta columna nos va a servir después para relacionarlo con el DataFrame de Departamento. También agregamos el Código de Localidad, al que le pusimos **id_depto**.

Para el DataFrame **BP** (Bibliotecas Populares), nos quedamos con los campos: **fecha de fundación**, **nombre**, **id del departamento**, **mail** y **provincia** (también usada momentáneamente). Además, le agregamos un **índice** que usamos como clave principal.

Después armamos el DataFrame **Departamento**, con los campos **id_depto**, **nombre** y **provincia**. Una vez creada esta tabla, ya podemos eliminar la columna Depto de Población y provincia de EE y BP, para no repetir información.

Por último, generamos las tablas **Niveles**, con el atributo **Sector**, y **Esta_formada_por**, que es la **relación entre EE y Niveles.**

## Decisiones tomadas

Población

- Agrupamos las edades según el grupo etario (jardín, primario, secundario, todos) para facilitar nuestro análisis de datos según lo pedido en la consigna
- Unificamos las comunas con id_depto = 2000 (como está escrito en BP) tratando a CABA como un departamento
- Modificamos los id_depto 94008 y 94015 correspondientes a Río Grande y Ushuaia por 94007 y 94014 ya que así se encontraban en las otras tablas. (Cuando queríamos construir la tabla Departamento nos dimos cuenta de este error ya que aparecían esos ids sin provincia)

EE

- Nos quedamos solamente con los datos correspondientes a la modalidad 'Común'
- Para obtener los id_depto tomamos de la columna 'codigo de localidad' en primer lugar a los de 'Ciudad de Buenos Aires' con id_depto=2000, y luego al resto si comienzan con cero se lo sacamos y nos quedamos con 5 digitos salvo para los de 'Jurisdicción' = 'Buenos Aires' que nos quedamos unicamente con 4 digitos para que coincidan con las otras tablas.
- Unificamos las comunas con id_depto = 2000 (como está escrito en BP) tratando a CABA como un departamento ??
- Renombramos la provincia 'Ciudad de Buenos Aires' por 'Ciudad Autónoma de Buenos Aires' para que coincida con la tabla de BP
-

BP

- Agregamos un Índice para usar como clave
- Nos quedamos únicamente con los dominios de la columna mail ya que es lo único que nos interesa de esa columna para el análisis. Además rellenamos los casilleros null por 'sin_dominio' en la nueva columna 'dominio'
- En la columna 'fecha_fundacion' modificamos también los valores null y los completamos poniendo 'sin fecha'

Departamento

Completamos manualmente algunos datos faltantes:

- Asignamos la provincia al departamento Tolhuin (con id_depto = 94011), ya que figuraba en la tabla de población pero no aparecía ni en BP ni en EE.

Comentario: Estuvimos revisando la cantidad total de departamentos en Argentina y, agrupando todas las comunas como si fueran un solo departamento de CABA, deberíamos tener 514 departamentos en total. Sin embargo, al generar nuestra tabla, nos dio 513.

Esto se debe a que la provincia de Tierra del Fuego tiene oficialmente cuatro departamentos: Río Grande, Tolhuin, Ushuaia y Antártida Argentina. Pero en el Censo 2022, no se consideró a Antártida Argentina como un departamento.

Por eso, en nuestra base de datos terminamos con 513 departamentos en lugar de 514.

Esta_formada_por

Unificamos los niveles educativos que estaban en la tabla original de Establecimientos Educativos para facilitar nuestro análisis. Agrupamos las categorías de la siguiente manera:

- “jardín”: incluye las columnas ‘Nivel inicial - Jardín maternal’ y ‘Nivel inicial - Jardín de infantes’.

- “primario”: toma directamente la columna ‘Primario’.

- “secundario”: agrupa ‘Secundario’ y ‘Secundario - INET’.

Por otro lado, los niveles ‘SNU’ y ‘SNU - INET’ no los tuvimos en cuenta, ya que no pudimos asociarlos a un grupo etario específico.

## Análisis de datos

### 1.Consultas SQL

Consulta 1:

En esta tabla se muestra la cantidad de EE de cada nivel educativo y la cantidad de habitantes por edad según los niveles educativos para cada departamento indicando la provincia y el nombre del mismo.

| Provincia | Departamento | Jardines | Poblacion_Jardin | Primarias | Poblacion_Primaria | Secundarios | Poblacion_Secundaria |
|---|---|---|---|---|---|---|---|
| Buenos Aires | La Matanza | 1300 | 157034 | 1332 | 225872 | 1340 | 181212 |
| Buenos Aires | La Plata | 928 | 52075 | 796 | 77998 | 824 | 67326 |
| Buenos Aires | Lomas de Zamora | 648 | 50825 | 712 | 76967 | 764 | 65257 |
| Buenos Aires | General Pueyrredón | 712 | 41427 | 676 | 62565 | 680 | 57730 |
| Buenos Aires | Quilmes | 648 | 47353 | 584 | 70881 | 612 | 60085 |
| Buenos Aires | Almirante Brown | 532 | 43762 | 548 | 67913 | 580 | 58227 |
| Buenos Aires | Moreno | 472 | 50791 | 536 | 76357 | 536 | 60359 |
| Buenos Aires | Merlo | 440 | 48007 | 480 | 71541 | 496 | 59718 |
| Buenos Aires | Lanús | 480 | 28133 | 464 | 44506 | 456 | 39855 |
| Buenos Aires | Tigre | 496 | 32611 | 444 | 51961 | 436 | 45401 |
| Buenos Aires | Pilar | 420 | 34493 | 436 | 49944 | 408 | 41528 |

Consulta 2:

En esta tabla se muestra la cantidad de BP fundadas desde 1950 para cada departamento indicando la provincia y el nombre del mismo.

| Provincia | Departamento | Cantidad_BP_Fundadas_Desde_1950 |
|---|---|---|
| Buenos Aires | La Matanza | 15 |
| Buenos Aires | La Plata | 15 |
| Buenos Aires | Moreno | 13 |
| Buenos Aires | Bahía Blanca | 13 |
| Buenos Aires | Tigre | 12 |
| Buenos Aires | Almirante Brown | 10 |
| Buenos Aires | Tandil | 10 |

Consulta 3:

En esta tabla se muestra la cantidad de BP, cantidad de EE (de modalidad común) y población total para cada departamento indicando la provincia y el nombre del mismo.

| Provincia | Departamento | Cantidad_EE | Cantidad_BP | Poblacion |
|---|---|---|---|---|
| Ciudad Autónoma de Buenos Aires | Ciudad Autónoma de Buenos Aires | 1782 | 43 | 3095454 |
| Córdoba | Capital | 1136 | 20 | 1498060 |
| Buenos Aires | La Matanza | 977 | 16 | 1837168 |
| Santa Fe | Rosario | 817 | 39 | 1337958 |
| Buenos Aires | La Plata | 669 | 33 | 756074 |
| Buenos Aires | Lomas de Zamora | 548 | 12 | 685644 |
| Buenos Aires | General Pueyrredón | 535 | 6 | 660569 |
| Buenos Aires | Quilmes | 464 | 9 | 631774 |
| Santa Fe | La Capital | 463 | 23 | 568259 |

Consigna 4:

En esta tabla se muestran los dominios de mail más frecuentes en BP para cada departamento indicando la provincia y el nombre del mismo.

| Departamento | Provincia | Dominio_mas_frecuente_en_BP |
|---|---|---|
| 12 de Octubre | Chaco | sin_dominio |
| 2 de Abril | Chaco | yahoo |
| 25 de Mayo | Buenos Aires | sin_dominio |
| 25 de Mayo | Chaco | yahoo |
| 25 de Mayo | Misiones | yahoo |
| 25 de Mayo | Río Negro | sin_dominio |

Comentario: La consulta devuelve más departamentos de los que realmente hay porque, en los casos donde dos o más dominios tienen la misma cantidad dentro de un mismo departamento, decidimos dejarlos todos en lugar de elegir solo uno. Es decir, si hay un empate, mostramos todos los dominios empatados.

## 2. Visualización

i.

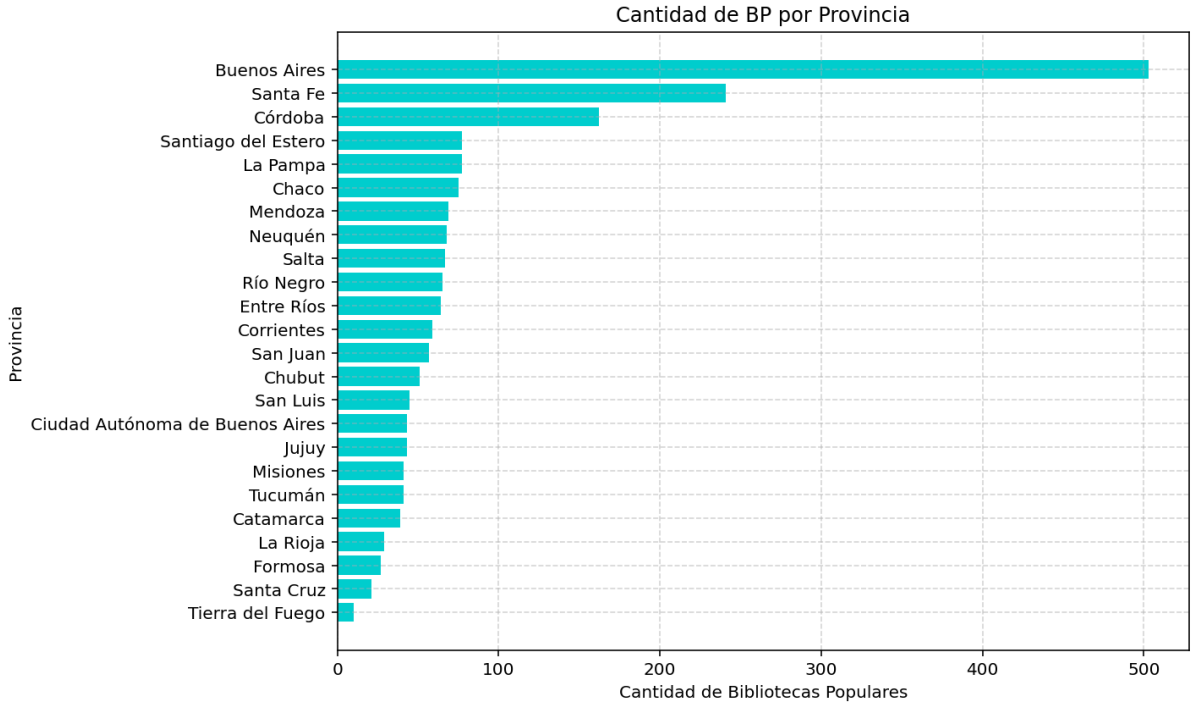


*Figura 1: Cantidad de BP por Provincia*

En la *Figura 1* se muestra un gráfico de barras, ordenadas de mayor a menor, según la cantidad de bibliotecas populares hay en cada provincia. Se observa claramente que Buenos Aires encabeza la lista con la mayor cantidad de BP, seguida de Santa Fe y Córdoba. En el otro extremo, Tierra del Fuego tiene apenas 10 bibliotecas.

ii.

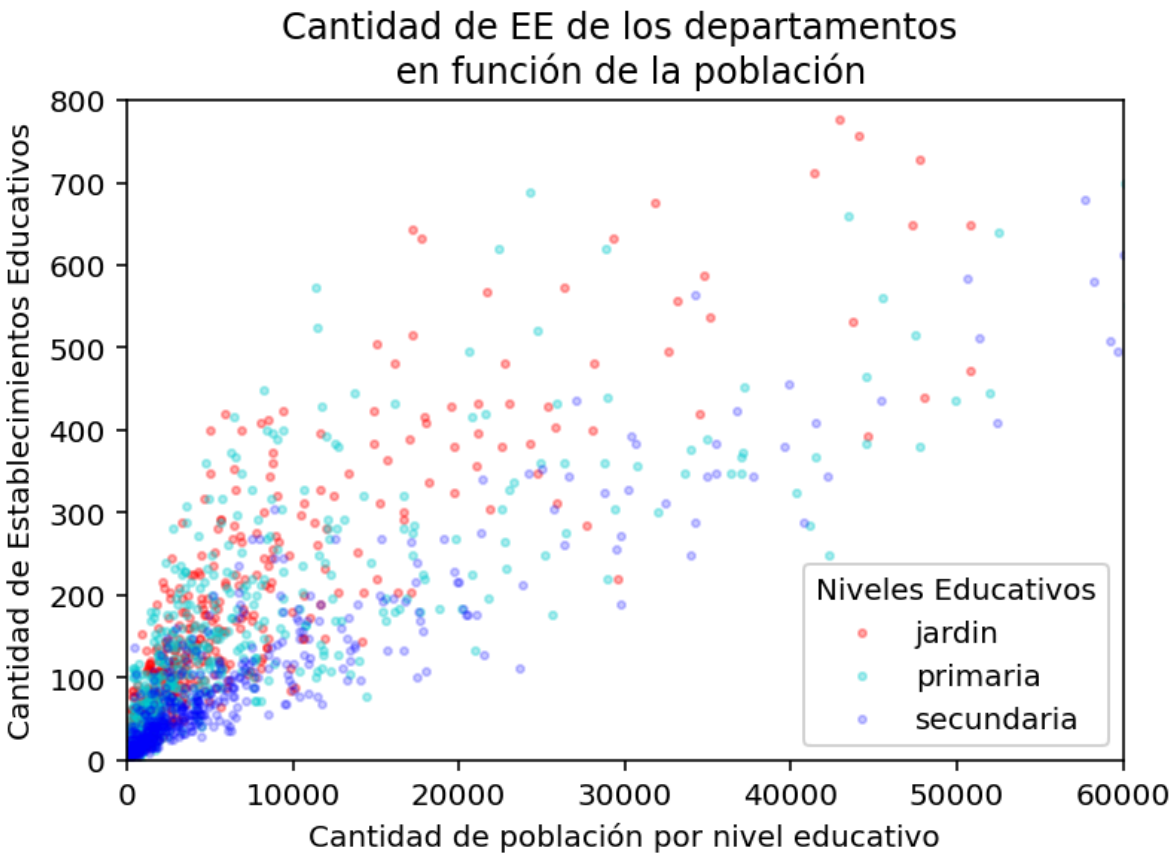


*Figura 2: Cantidad de EE por Departamento en función de la Provincia*

En la figura 2 se observa una tendencia creciente: a medida que aumenta la población por nivel educativo, también aumenta la cantidad de establecimientos educativos, lo cual es esperable. Sin embargo, hay una alta concentración de puntos en valores bajos, indicando que la mayoría de los departamentos tienen poblaciones y cantidades de EE relativamente bajas. También se nota que los establecimientos de nivel jardín y primaria son más numerosos que los de secundaria, posiblemente reflejando una mayor cobertura en los niveles iniciales de la educación.

iii.

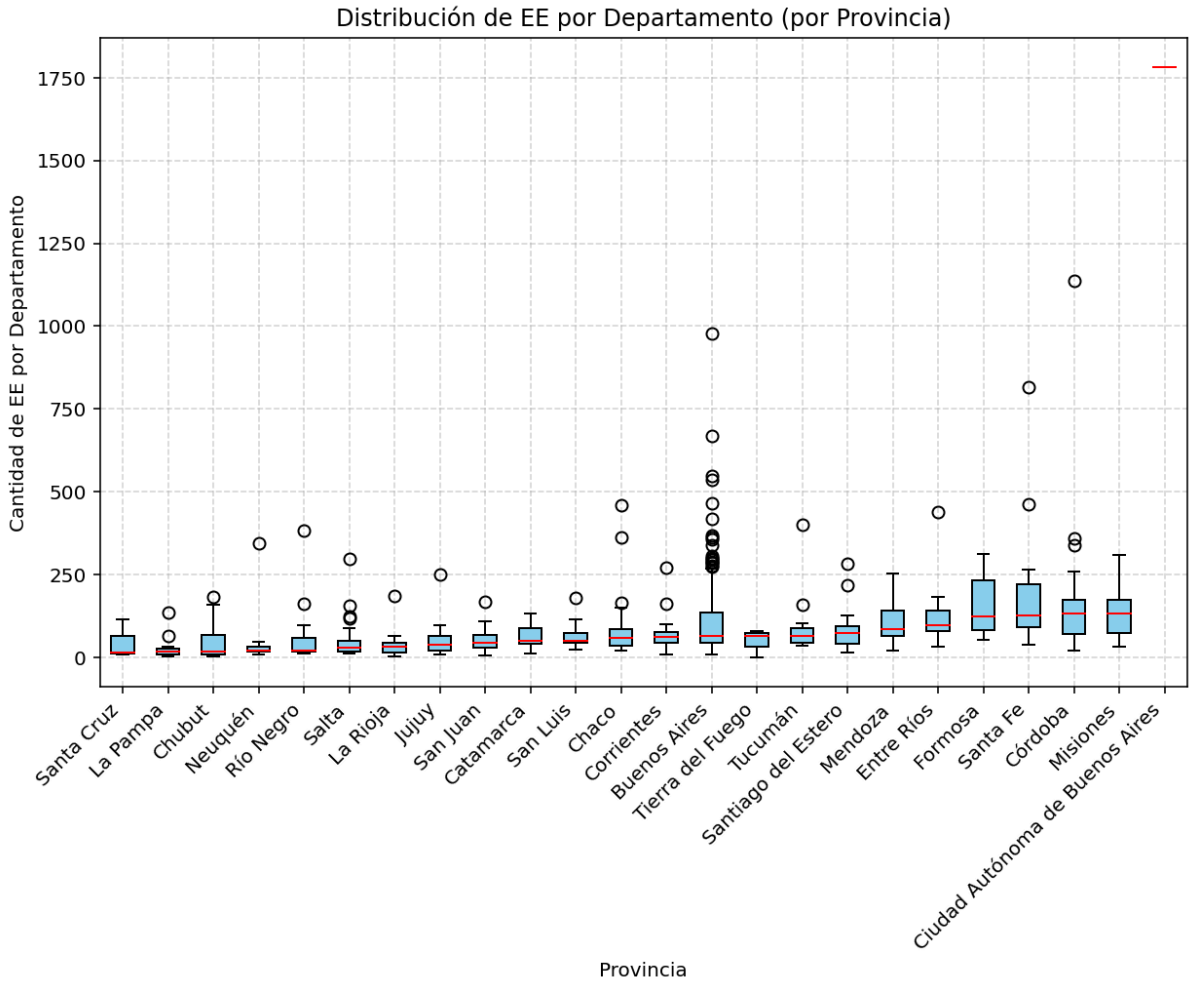


*Figura 3: Cantidad de EE por cada Departamento de las Provincias*

En la figura 3 se observa una alta variabilidad entre provincias en cuanto a la distribución de EE por departamento.

La Ciudad Autónoma de Buenos Aires presenta un valor atípico muy elevado (fuera del rango de la gráfica), lo que indica que este departamento concentra una cantidad extremadamente alta de EE en comparación con otros.

Se observan muchos outliers en provincias como Buenos Aires y Córdoba; esto muestra que dentro de estas provincias existen departamentos con un número muy alto de EE y otros con cifras más moderadas. Esto indica que, aunque la mediana de EE en cada provincia parezca parecida, la distribución no es homogénea en todas ellas.

Por otro lado, hay una distribución más homogénea en provincias de menor densidad. Por ejemplo como en Santa Cruz, La Pampa, Chubut y Catamarca se muestran medianas relativamente bajas y rangos cortos.

iv.

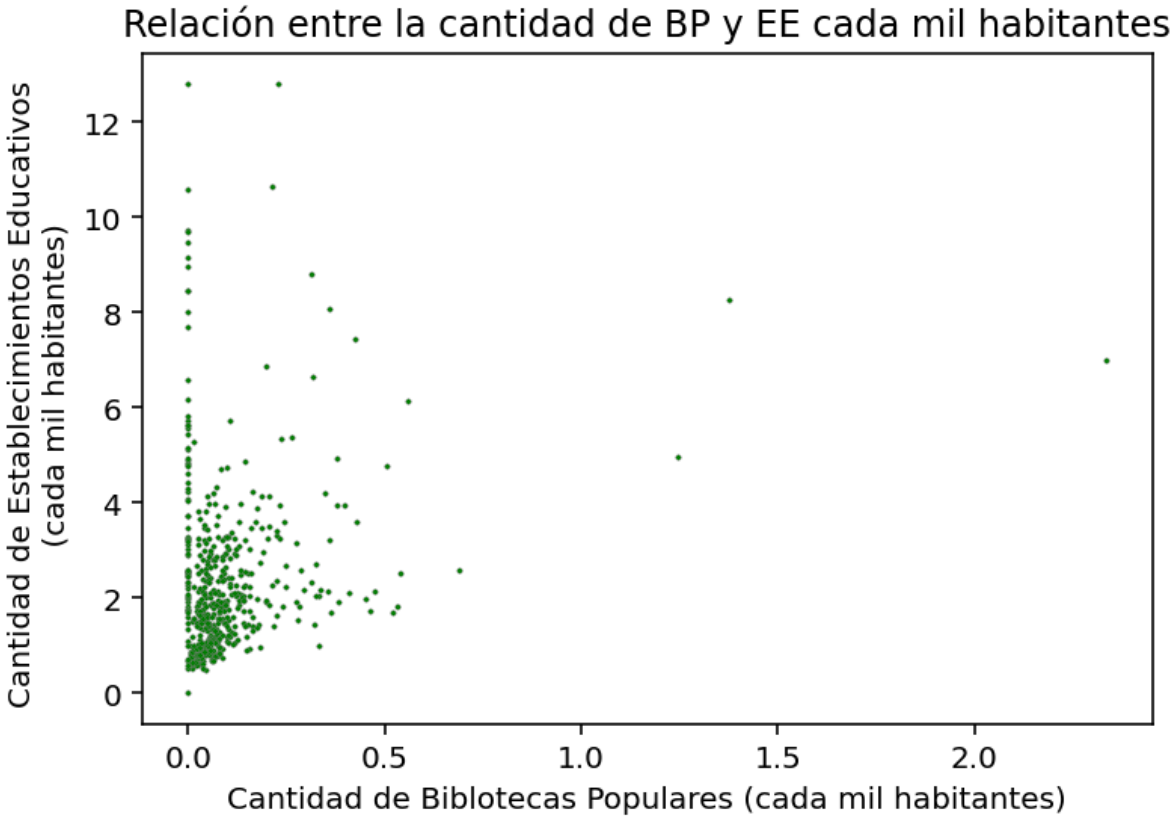


*Figura 4: Cantidad de BP y EE cada mil habitantes por departamento*

En la *Figura 4* podemos observar que si bien no vemos una relación muy marcada, es evidente que a menor cantidad de BP, existe una menor cantidad de EE. Se puede ver una relación lineal de tendencia creciente con respecto a la población, sin embargo es muy evidente que hay muchos casos de departamentos que tienen muy pocas Bibliotecas Populares y distintas cantidades de Establecimientos Educativos.

El resto de outliers no tiene un patrón claro, solamente se encuentran dispersos. Esto es correlativo a lo que visualizamos en la figura I y III, donde provincias como Formosa tienen una gran cantidad de EE, pero muy poca cantidad de BP. En las provincias donde hay muy pocas BP, podemos ver que la cantidad de EE es muy variable: puede tener muchos EE o pocos. Por lo tanto podemos deducir que entran en juego otros factores además de la cantidad de BP, para determinar la cantidad de EE por departamento

## CONCLUSIÓN DEL TRABAJO

A partir del análisis realizado en este informe, podemos concluir que no existe una relación directa entre la cantidad de Establecimientos Educativos y la de Bibliotecas Populares. Si bien se observa una ligera tendencia creciente en función de la población, la amplia dispersión de los datos y el elevado número de departamentos con baja densidad de bibliotecas, pero con variaciones significativas en la cantidad de establecimientos educativos, impiden establecer una correlación sólida entre ambos indicadores.

Como mencionamos anteriormente en el análisis de la Figura 4, deducimos que un elevado número de EE por cada mil habitantes no asegura, una alta densidad de BP, ni vice versa. Consideramos que esto se debe a otros aspectos que no estamos teniendo en cuenta en el análisis de este informe, como por ejemplo: factores culturales, de financiamiento o gestión de cada provincia. Posiblemente al incluir variables adicionales de otras fuentes de datos podríamos llegar a conclusiones más precisas.